

구조적 세계모형의 봉인 평가: OOD 일반화, 개방루프 전개와 학습 라우팅 준거 검증

하철수

개정일: 2026년 8월 20일

Abstract

세계모형 오차는 scalar loss를 유지하면서 의사결정에 필요한 structural dependency를 위반할 수 있다. 사전등록한 세 exact-state 연구는 먼저 structural OOD, open-loop rollout과 task-level criterion association을 평가했다. 첫 두 연구에서는 correct routing이 random 및 wrong routing과 분리됐지만, four-arm criterion estimand에서는 wrong-routed arm도 point-effect threshold를 넘어 routing correctness가 식별되지 않았다. 이에 새로운 prospective stochastic 연구의 source 동결, fresh seed 생성과 one-shot 실행을 하나의 scripted sequence에서 그 순서대로 수행했다. 120개 independent world는 30개 two-edge graph motif와 세 transition-head family를 교차하며, 이중 두 family는 원래의 linear TSI 식 밖에 있다. 800개 noisy primitive transition과 400개 selection transition에서 structure와 head family를 선택한 뒤, 1,200개 더 noisy한 two-coordinate composition 및 world당 160개 six-step rollout으로 평가했다. Learned graph와 head 회수율은 1.000이었고 multiplicity-adjusted Wilson 하한은 0.941이었다. Shifted routing 대비 learned routing은 composition negative log likelihood를 0.35933, open-loop normalized Hamming area를 0.08996 개선했다. Development에서 적합하고 동결한 calibration으로 첫 세 transition의 discrepancy가 terminal failure를 예측하게 했을 때, correct routing은 shifted routing보다 Brier score를 0.02402 개선했고 simultaneous interval은 [0.01808, 0.02997]이었다. Frozen gate 아홉 개가 모두 통과했으며 outside-family noninferiority도 포함된다. 이 cohort, root seed와 여덟-quantity multiplicity family는 Paper 4와 공유한다. 여기서 보고하는 endpoint는 하나의 frozen analysis 중 일부이며 독립 evidence가 아니다. 별도의 Node.js 구현은 120개 learned fit과 analysis mean 열 개를 모두 재현했다. 따라서 새 evidence는 선언한 stochastic family에서 routing correctness를 해결하지만, 이전 pooled association을 같은 결과로 소급 변경하지 않는다.

1 서론

Joint-embedding predictive architecture와 structured world model은 모든 관측 coordinate를 복원하지 않고도 prediction과 planning을 지원하는 representation을 학습하고자 한다 [1, 2, 6]. 그러나 하나의 scalar latent loss는 structured state의 어느 부분이 실패했는지 식별하지 못한다. 같은 latent error를 가진 두 prediction도 typed label, edge, metric comparison, directed relation 또는 order constraint의 보존 여부에서는 크게 다를 수 있다. Utility가 average latent fidelity가 아니라 이 predicate 중 하나에 의존할 때 이러한 차이가 중요하다.

본 논문은 일반적인 world-model superiority보다 좁은 질문을 다룬다. 선언된 finite structural signature 아래에서 structural discrepancy가 matched scalar baseline에 남는 error를 검출하는가, 그리고 이 discrepancy가 independent world generation, open-loop composition과 plan selection에서도 informative한가? Mathematical interface는 다섯 layer 전체에 하나의 typed correspondence를 사용한다. Correspondence-based distance는 metric 및 structured object를 비교하는 확립된 도구다 [7, 10]. 여기서 일반적인 correspondence 개념 자체를 새 기여로 주장하지 않는다. 본 연구의 기여는 coherent multi-layer state, codebook-free constructive decoding, routing-specific control과 failure-preserving sealed evaluation을 동결된 형태로 결합한 것이다.

Empirical study는 네 설계 원칙을 따른다.

- (i) Development world와 sealed world는 서로 다른 committed seed로 생성하고 각 sealed gate를 한 번만 실행한다.
- (ii) 여섯 control은 input information, active-parameter count, optimization update와 tuning budget을 공유한다.
- (iii) Transition이나 task가 아니라 world를 independent inferential unit으로 사용하고 optimizer seed는 nested replicate로 둔다.
- (iv) Positive result와 failed boundary를 함께 보고한다.

세 gate를 평가한다. 첫 gate는 unseen mechanism에서 structural out-of-distribution(OOD) prediction을 검정한다. 둘째 gate는 horizon 32까지 recursive open-loop error를 검정한다. 셋째 gate는 task-local structural discrepancy가 plan failure의 frozen probabilistic model을 개선하는지 묻는다. Proper Brier score를 probabilistic criterion으로 사용하고 [4], discrete-time hazard로 first-failure timing을 표현한다 [8]. Predictor는 leave-one-world-out development assessment 뒤 sealed evaluation 전에 동결하며, model development data와 evaluation data를 분리하는 일반 원칙을 따른다 [3, 9].

Structural prediction에는 raw observation에서 entity discovery, 시간에 걸친 identity, relation, structural variable과 dependency graph를 거쳐 prediction에 이르는 chain이 필요하다. 본 연구는 이 chain의 후반 단계를 다룬다. Entity set과 cross-time identity는 generator가 제공하며, 이들이 주어진 뒤의 graph recovery와 prediction을 검정한다. Raw observation에서 entity를 발견하고 그 identity를 유지하는 문제는 본 논문의 estimand 밖에 있다.

셋째 gate는 prespecified primary analysis를 통과하지만 해석 범위는 의도적으로 제한한다. Discrepancy와 regret label은 동일한 held-out candidate trajectory를 공유하므로, oracle endpoint 없이 사용할 수 있는 deployment-time prognosis가 아니라 same-task criterion association이다. 또한 stronger raw layer-aware sensitivity는 prespecified effect floor에 도달하지 못했고, temporally separated development diagnostic 두 개도 실패했다. 이 negative result는 scalar-baseline 결과를 full correspondence metric이 모든 layerwise structural audit보다 우월하다는 증거로 읽지 못하게 한다.

2 동결된 구조 interface

2.1 Coherent state

Finite typed schema와 positive signature Θ 를 고정한다. State는

$$\Sigma = (F, \lambda, K, d, \preceq; \Theta) \in \text{CState}(\Theta)$$

형태다. 여기서 F 는 finite typed relation을 표현하고, λ 는 tagged label, K 는 tagged carrier 위 simplicial complex, d 는 intrinsic metric, $\preceq$ 는 finite preorder다. 선언된 cross-layer bridge는 optional penalty가 아니라 $\text{CState}(\Theta)$ 의 membership condition이다.

State Σ, Γ 에 대한 typed correspondence $C \in \text{Corr}(\Sigma, \Gamma)$ 는 양 coordinate projection이 surjective인 type-preserving relation의 family다. 같은 C 로 label, simplicial, normalized metric, relational, order distortion

$$\delta_\lambda(C), \quad \delta_K(C), \quad \delta_d(C), \quad \delta_R(C), \quad \delta_P(C)$$

를 계산한다. Θ 가 고정한 positive weight 아래 quotient discrepancy는

$$\Delta_\Theta(\Sigma, \Gamma) = \min_{C \in \text{Corr}(\Sigma, \Gamma)} (w_\lambda \delta_\lambda(C) + w_K \delta_K(C) + w_d \delta_d(C) + w_R \delta_R(C) + w_P \delta_P(C))$$

이다. Companion theory는 quotient 전에는 pseudometric이고 structural-isomorphism class 위에서는 metric임을 증명한다. Empirical code는 finite benchmark에서 exact minimizing correspondence를 계산한다.

2.2 Fixed-carrier audit

Benchmark는 stable typed identifier도 유지한다. 이 fixed alignment 아래에서

$$e_{\text{fix}} = (e_\lambda, e_K, e_d, e_R, e_P)$$

와 signature-weighted total을 기록한다. 이 audit는 quotient equality보다 강하다. Isomorphic하지만 presented identifier가 일치하지 않는 두 state를 구별할 수 있다. Quotient quantity와 fixed-carrier quantity를 분리 보고한다.

2.3 Constructive decoding과 routing

각 model은 layerwise categorical decision을 출력하며, shared constructive operator가 이를 valid state로 바꾼다. Topology closure, metric closure, declared relational channel과 reflexive-transitive order closure를 사용한다. Primary decoder는 held-out target state의 enumerated list에 projection하지 않는다.

여섯 control은 다음과 같다.

- (1) matched active dense model,
- (2) layer-routed dense-action model,
- (3) strict factorized-action model,
- (4) oracle signature-routed model,
- (5) matched sparsity의 random-routed model,
- (6) permuted 또는 wrong-routed model.

이들은 같은 observable field를 받고 420개 active parameter와 동일한 optimization budget을 사용한다. Oracle signature routing은 upper-bound control이며 learned structure discovery가 아니다.

2.4 Task outcome

각 criterion-validity task는 두 candidate action plan을 제공한다. Exogenous utility는 primary structural predicate와 secondary structural predicate를 각각 weight 2와 1로 검사한다. Model prediction이 선택한 plan을 $\hat{j}$, oracle-best plan을 j^* 라 하면 regret은

$$\mathcal{R} = U(\Sigma_{j^*}) - U(\Sigma_{\hat{j}}), \quad Y = \mathbf{1}\{\mathcal{R} > 0\}$$

이다. Correspondence discrepancy, fixed-layer loss 또는 fitted predictor는 generator, utility, regret, failure label에 들어가지 않는다.

3 봉인된 다중 gate 설계

3.1 Cohort와 one-shot access

Table 1는 세 confirmatory cohort를 요약한다. 각 gate에는 development generator, 별도의 encrypted seed commitment, zero-access audit, frozen source digest와 atomic one-shot lock이 있다. Sealed result를 threshold, feature, model population 또는 sample size 변경에 재사용하지 않는다.

Table 1: Confirmatory cohort. Run 수는 world 수, 여섯 control과 세 optimizer seed의 곱이다.

Gate	Worlds	Runs	최대 horizon	Primary 목적
Structural OOD	50	900	1	unseen mechanism과 routing
Open-loop rollout	62	1,116	32	recursive structural error
Criterion validity	69	1,242	8	plan failure와 first failure

OOD와 rollout gate는 paired comparison에 여섯 control 전체를 사용한다. Criterion-validity gate는 nondegenerate error를 생성하는 네 control에서 hazard model을 fit한다. Dense와 oracle-signature control은 mandatory structural-zero check로 유지하며 report에서 제거하지 않는다.

3.2 Structural OOD gate

Development mechanism과 sealed mechanism은 world level에서 disjoint하다. Generator는 unseen recombination, unseen structural mode, unseen mechanism parameter, unseen action composition, bridge-consistent shift와 bridge-violating negative control을 구분한다. Primary comparison은 capacity와 compute를 유지하면서 correct routing을 random/wrong routing과 pair한다. Frozen power rule로 sealed world 50개를 선택했다.

3.3 Open-loop gate

Rollout protocol은 horizon 1, 2, 4, 8, 16, 32에서 teacher-forced prediction과 recursive prediction을 분리한다. Δ_Θ trajectory의 area, fixed-layer vector, structural failure 없는 survival, bridge violation과 tracking diagnostic을 기록한다. 누적 worst-case numerical bound가 vacuous하더라도 recursive inequality audit를 유지한다.

3.4 Criterion-validity gate

각 world는 32개 unit을 가진다. 한 unit에는 domain-separated 8-step probe와

$$(1, 2, 4, 8, 1, 2, 4, 8)$$

horizon을 가진 task 8개가 있다. Task utility는 structural predicate만으로 생성한다. Primary population은 layer-routed, strict-factorized, random-routed, wrong-routed control이다.

Scalar baseline은 training negative log likelihood, one-step/open-loop latent mean-squared error, endpoint exactness, task horizon과 goal weight, model identity, plan-selection margin, selected-versus-alternative scalar error contrast를 포함한다. Augmented model은 prespecified task-local Δ_Θ , fixed-total, fixed-layer와 goal-aligned structural contrast를 추가한다. Mandatory non-gating sensitivity는 baseline에 direct raw layer mismatch를 제공한다.

Ridge logistic discrete hazard $h_i(t)$ 를 development world에서 fit 한다. Cumulative failure probability는

$$\hat{F}_i(t) = 1 - \prod_{s=1}^t \{1 - \hat{h}_i(s)\}$$

이다. 모든 coefficient, feature order, mean, scale과 penalty를 sealed seed reveal 전에 동결한다.

3.5 Estimand와 inference

두 co-primary effect는

$$\begin{aligned}\mathcal{E}_{\text{bin}} &= \text{BS}_{\text{scalar}}(8) - \text{BS}_{\text{TSI}}(8), \\ \mathcal{E}_{\text{int}} &= \frac{1}{8} \sum_{t=1}^8 [\text{BS}_{\text{scalar}}(t) - \text{BS}_{\text{TSI}}(t)].\end{aligned}$$

이다. 여기서 BS(8)의 8은 task identifier가 아니라 고정된 8-step candidate trajectory의 terminal time index $t = 8$ 이다. Integrated estimand는 이 trajectory의 8개 time index를 평균한다. 양수이면 structural augmentation이 우세하다. Unit-level score는 world 안에서 primary control과 nested optimizer seed에 대해 먼저 평균한다. One-sided world-level Student test에는 Holm familywise correction을 적용한다 [5]. 또한 20,000-replicate world-cluster bootstrap과 world-random-intercept, seed-nested variance decomposition에서 Bonferroni simultaneous lower bound가 양수여야 한다. 두 point effect는 prespecified smallest effect size of interest $\varepsilon_{\min} = 0.0025$ 를 만족해야 한다. Inferential null은 nonpositive effect이며 confidence lower bound가 $\varepsilon_{\min}$ 를 넘는다고 주장하지 않는다.

4 Structural OOD 결과

계획한 900개 fit이 numerical failure 없이 완료됐다. Codebook-free decoder는 valid structural state를 생성했고 paired information, parameter, update, tuning audit가 통과했다.

Primary sealed structural-OOD endpoint에서 oracle signature-routed control과 matched dense exact control의 error는 0이었다. Signature-routed control 대비 matched random routing과 permuted/wrong routing은 machine precision에서 동일한 paired structural effect 0.1943489362와 동일한 world SD 0.0011631을 보였다. 따라서 이 cohort에서 두 control은 oracle routing과는 구분되지만 서로 간에는 구분되지 않는다. Dense noninferiority margin은 floating-point error를 제외하면 결정론적 상수 0.05였고 world SD는 2.10×10^{-17} 였다. Frozen Holm, world-cluster bootstrap, hierarchical world/seed decision은 양수였지만 극단적인 p -value는 넓은 일반화의 독립 증거가 아니라 저분산 synthetic margin을 기술한다.

이 결과는 finite oracle-signature regime에서 declared routing mask의 가치를 식별한다. Mask를 data에서 발견할 수 있음을 보이지 않는다. Unseen mechanism-parameter slice의 signature-routing error 0.11995는 남았다. 이는 aggregate에서 제거한 예외가 아니라 보존된 failure boundary다.

5 Open-loop rollout 결과

Rollout gate는 62개 fresh sealed context world의 1,116개 fit 전체를 완료했다. Oracle signature-routed와 matched dense control의 32-step open-loop Δ_{Θ} area는 0이고 unit structural survival은 1이었다. Signature control 대비 random-routed와 wrong-routed control의 mean open-loop area effect는 각각 0.17457, 0.17490이었다. Frozen family에는 co-primary margin 8개가 있었다. 이 중 6개는

between-world SD가 사실상 0인 결정론적 structural margin으로, 값은 0.10, 0.15, 그리고 네 개의 0.05였다. 실질적인 확률 변동을 가진 것은 random- 및 wrong-routing 비교 두 개뿐이며 between-world SD는 각각 0.01196, 0.01120였다. 기록된 여덟 decision은 multiplicity, cluster-bootstrap, hierarchical processing 뒤 모두 양수였지만, 이는 독립적이고 정보적인 검정 여덟 개를 뜻하지 않는다. 확률적 정보는 두 routing 비교에 있다.

Tracking error는 모든 control에서 0이었다. 이는 consistency check이지만 fixed-cardinality world에서 routing quality를 식별하지 않는다. Exact recursive inequality도 finite audit를 통과했지만 failed control의 global worst-case bound는 약 1.24×10^{13} 까지 증가했다. 따라서 이 bound는 proof-valid하지만 해당 regime에서 numerically vacuous하다. 어느 결과도 positive tracking 또는 stability claim으로 바꾸지 않는다.

6 과업 수준 준거 연관성 결과

6.1 Development freeze

첫 development specification은 sealed reveal 전에 실패했다. Leave-one-world-out improvement는 terminal Brier score에서 0.000421, integrated score에서 -0.000221 이었다. Effect floor를 낮추지 않았다. Revised specification은 exogenous task utility를 mode equality에서 structural predicate로 바꾸고, task-varying hazard와 scalar selected-versus-alternative contrast를 사용했으며, world당 unit을 16에서 32로 늘리고 stronger layer-aware sensitivity를 유지했다.

Revised development world 24개에서 primary event rate는 0.60384였다. Leave-one-world-out terminal/integrated improvement는 각각 0.003124, 0.003927 이었다. Analytic floor와 20,000-draw conjunctive Holm power simulation으로 sealed world 69개를 선택했다. Simulated conjunctive power는 0.9208, Monte Carlo 95% lower bound는 0.91698 이었다.

6.2 Sealed primary analysis

Sealed fit 1,242 개가 모두 완료됐다. Primary population은 $26,496 = 69 \times 32 \times 3 \times 4$ 개 unit record(world, unit, nested optimizer seed, primary arm)를 포함했고 event rate는 0.61632였다. 두 exact control의 event rate는 0을 유지했다. Table 2는 co-primary analysis를 보인다.

Table 2: 69개 world의 frozen co-primary criterion-validity 결과. Bootstrap과 hierarchical column은 0에 대한 simultaneous lower bound다.

Effect	Mean	World SD	Holm p	Bootstrap LB	Hierarchical LB
Terminal Brier	0.003519	0.009015	0.001230	0.001428	0.001392
Integrated first failure	0.003034	0.007471	0.001230	0.001296	0.001271

두 mean은 $\varepsilon_{\min} = 0.0025$ 를 넘는다. Mean terminal Brier score는 0.183661에서 0.180143으로, integrated Brier score는 0.148317에서 0.145283으로 감소했다. Outcome noncircularity, panel completeness, event balance, no-refitting, exact-control structural zero, Holm, cluster-bootstrap, hierarchical requirement가 모두 통과했다.

Pooled estimand는 이질적인 네 arm을 평균한다. 따라서 routing interpretation에 앞서 사전지정 secondary arm decomposition을 Table 3에 보고한다.

Wrong-routed arm은 두 outcome 모두에서 $\varepsilon_{\min}$ 를 넘고 random-routed arm은 integrated outcome에서 이를 넘는다. 따라서 pooled criterion analysis는 structural augmentation과 same-task

Table 3: Frozen scalar model 대비 arm-level Brier improvement. 별도로 multiplicity gate를 적용한 estimand가 아니라 secondary descriptive effect 다.

Arm	Terminal	Integrated
Layer-routed dense	0.005402	0.003222
Strict factorized	0.003114	0.003077
Random-routed matched sparsity	0.002445	0.002758
Permuted or wrong-routed	0.003114	0.003077

outcome 사이의 association을 식별하지만 routing correctness의 효과를 식별하지 않는다. Layer-routed dense의 descriptive effect가 strict factorization보다 크다는 사실도 factorization을 작동 성분으로 분리하지 못한다.

6.3 Sensitivity와 temporal boundary

Generic baseline에 direct raw layer mismatch를 추가했을 때 structural augmentation의 terminal/integrated Brier improvement는 0.002108, 0.001467 이었다. 양수이지만 $\varepsilon_{\min}$ 미만이다. 따라서 primary result는 scalar generic baseline을 넘는 increment를 확립하지만 prespecified layer-aware baseline을 넘는 practically nontrivial advantage는 확립하지 않는다.

더 강한 temporal interpretation 두 개를 development data에서만 검사했으며 모두 실패했다. Independent probe로 later task failure를 예측했을 때 -0.000539 , -0.000212 였고, 처음 네 task를 calibration으로 사용해 뒤 네 task를 예측했을 때 -0.002021 , -0.001069 였다. 따라서 sealed positive result는 oracle candidate endpoint를 사용하는 same-task criterion association이다. Future-task prognosis 또는 oracle-free deployment score의 evidence가 아니다.

7 Prospective 라우팅 해소 연구

7.1 동결 설계

새 256-bit root seed를 생성하기 전에 follow-up estimand와 source를 동결했다. 동결, seed 생성과 one-shot 실행은 하나의 scripted sequence에서 그 순서대로 진행했다. 무결성은 경과 시간 간격이 아니라 frozen hash와 seed commitment에서 나온다. 120개 independent world는 각각 modulo 7인 다섯 coordinate와, 서로 다른 두 source가 하나의 공통 target으로 들어가는 graph motif 하나를 가진다. 가능한 30개 motif를 다음 edge head와 교차했다.

$$a_s(1 + x_t), \quad a_s(1 + x_t)^2, \quad a_s(1 + x_s + x_t).$$

World의 1/3은 원래 linear head 두 개를 사용하고, 2/3는 나머지 head를 적어도 하나 사용한다. Coordinate noise 0.08인 primitive-action transition 800개에서 direct multiplier와 edge coefficient 두 개를 적합했다. 서로 겹치지 않는 transition 400개로 graph와 head family를 선택했다. 두 active action coordinate와 coordinate noise 0.12를 갖는 OOD transition 1,200개는 어떤 적합에도 사용하지 않았다. 지정한 composition stratum은 두 causal edge를 동시에 활성화한다.

Criterion 비교는 동일한 learned predictor에 두 routing map을 적용한다. Six-step stochastic trajectory의 첫 세 step에서 correct score는 learned source 중 하나가 활성일 때 target-coordinate discrepancy를 기록하고, negative control은 동일한 discrepancy field를 고정 shifted graph로 routing한다. 24개 public development world에서 적합한 logistic map을 confirmation 전에 동결했다. Outcome은 learned target의 terminal mismatch이며 estimand는 wrong-routing Brier score에서

correct-routing Brier score를 뺀 값이다. 따라서 outcome에는 어느 criterion score도 들어가지 않고, diagnostic은 terminal outcome보다 앞서며, 두 arm의 차이는 routing뿐이다.

여덟 inferential quantity에는 familywise level 0.05의 Bonferroni simultaneous two-sided interval을 사용했다. Identification gate는 0.90의 simultaneous Wilson 하한도 요구한다. Point-effect threshold는 learned composition NLL contrast 0.04, rollout Hamming area 0.025, criterion Brier score 0.005이다. 이 point threshold는 simultaneous interval의 null boundary와 구별된다.

전체 nine-gate conjunction은 graph-head identification, learned-routing NLL, factorized-head graph NLL, generic-head graph NLL, dense-head graph NLL, matched-head predictive equivalence, rollout Hamming, criterion Brier, outside-family noninferiority로 구성된다. Post-freeze reporting clarification은 나머지 여덟 항목을 inferential quantity로 열거하고, matched-head equivalence는 별도의 아홉 번째 decision gate로 둔다. 이 gate는 보고된 simultaneous interval에 frozen equivalence margin 0.01을 적용한다. Matched support를 회수하면 정확한 함수적 동치에 의해 관측 contrast는 0이 된다.

Analysis object는 frozen Bonferroni divisor 8로 interval-bearing quantity 열 개를 보고한다. 여기에는 exact duplicate pair 하나, sign-flipped pair 하나와 deterministic zero 하나가 있어 정보적으로 구별되는 stochastic quantity는 일곱 개다. Frozen v1 contract는 정수 divisor만 지정하고 구성원을 열거하지 않았다. 이는 reporting defect이며 사전등록된 family 정의가 아니다. Post-review sensitivity에서 divisor 10을 사용해도 모든 decision은 유지된다. Cohort, root seed와 multiplicity family는 Paper 4와 공유한다. 여기서 보고하는 세 endpoint는 하나의 frozen analysis 중 일부이며 독립 evidence가 아니다.

Confirmation 전에 120개 world에 대한 power analysis를 동결하지 않았다. Post-review retrospective design justification은 development world 24개만 사용한 stratified bootstrap 20,000회에서 nine-gate conjunctive power를 0.9694, Monte Carlo interval을 [0.9670, 0.9718]로 추정한다. 이 계산은 confirmatory result를 사용하지 않으며 사전등록된 sample-size rationale을 소급 확립할 수 없다.

7.2 Confirmatory 결과

120개 world 모두에서 learned motif와 두 head family를 회수했다(rate 1.000; simultaneous Wilson 하한 0.941). 표 4은 Paper 3의 세 endpoint를 보고한다. 모든 interval은 world 간에 계산했고 case와 rollout은 nested observation이다.

Table 4: Prospective learned-routing effect. 양수는 learned 또는 correct routing에 유리하다.

Endpoint	Mean	World SD	Simultaneous interval
Composition NLL	0.35933	0.02012	[0.35431, 0.36435]
Rollout Hamming area	0.08996	0.01162	[0.08706, 0.09286]
Routing-correct Brier	0.02402	0.02381	[0.01808, 0.02997]

세 point effect는 모두 frozen threshold를 넘고 simultaneous 하한도 모두 0보다 크다. 원래 linear family 밖의 80개 world 성능은 40개 linear world에 noninferior했다. Outside-minus-linear NLL은 -0.00132, simultaneous interval은 [-0.01031, 0.00766]이었고 상한은 margin 0.03보다 작다. 이는 direct learned-routing criterion 결과이며 이전 four-arm 평균의 재해석이 아니다.

별도 post-review descriptive sensitivity는 train noise 0.04, 0.08, 0.16과 OOD noise 0.06, 0.12, 0.24를 교차했다. 각 cell에는 public-seed world 120개를 사용했다. Graph와 head 회수율은 아홉 cell 모두 1.000을 유지했다. Learned-routing NLL effect의 최소 평균은 0.23337이었다. 이 panel은 confirmatory가 아니며 선언한 coordinate-corruption process만 변화시킨다.

8 범위와 한계

Structural discovery의 범위. 승격된 structure 결과는 primitive transition에서 observation-only algorithmic graph discovery를 수행한 뒤 factorized parameter recovery를 적용한다. 따라서 unconstrained neural network가 동일 graph를 스스로 발견한다고 확립하지 않는다. Neural structure track은 exploratory로 남긴다.

Synthetic bounded-cardinality regime. 모든 confirmatory world는 선언된 finite synthetic family에서 나온다. Variable- cardinality audit는 세 개의 finite cardinality panel을 포함하지만 birth, death와 held-out entity identity turnover는 없다. 따라서 zero transition error는 turnover 아래 identity maintenance를 검정하지 않는다.

Temporal validity가 아닌 criterion validity. Task-local discrepancy와 regret outcome은 동일한 held-out candidate trajectory를 사용한다. TSI는 outcome definition에 들어가지 않지만 generic error comparator와 structural discrepancy를 계산하려면 oracle endpoint가 필요하다. Temporally separated diagnostic의 실패는 현재 benchmark에서 더 강한 prognostic interpretation을 배제한다.

기존 co-primary criterion estimand는 random 및 wrong routing을 포함한 네 arm을 평균한다. Wrong routing이 두 outcome 모두에서 point-effect threshold를 넘으므로 그 analysis는 routing-correctness test가 아니다. Prospective 연구는 direct correct-versus-shifted routing estimand로 이 특정 ambiguity를 해결하지만, historical cohort의 estimand나 해석을 바꾸지 않는다.

Comparator dependence. Co-primary improvement는 scalar generic model 대비 결과다. Layer-aware sensitivity는 양수지만 effect floor 미만이다. 따라서 현재 evidence는 common- correspondence optimization 자체가 모든 단순 layerwise structural description보다 우월하다고 식별하지 않는다.

Magnitude와 uncertainty. Brier improvement는 작다. Simultaneous lower bound는 양수지만 0.0025 point-effect threshold를 넘지 않는다. Analysis는 positive effect와 threshold 이상의 point estimate를 지지하지만 population effect가 95% confidence로 threshold를 넘는다고 확립하지 않는다.

External validity와 noise 경계. Prospective 결과는 finite state space에서 stochastic coordinate corruption, 세 head family, learned routing과 held-out two-mechanism composition을 다룬다. Project import가 없는 Node.js code path가 120개 learned factorized fit과 보고한 analysis mean 열 개를 모두 재현한다. 이는 independent implementation check이지 independent research-group study가 아니다. Visual input, entity turnover와 real-world system은 정의한 population 밖이며 이 결과에서 추론하지 않는다.

9 재현성과 artifact 무결성

개정 bundle은 implementation, generator, frozen predictor, analysis plan, access ledger, raw result, report와 final scope audit를 package-relative `src/`, `experiments/` 및 `reproduction/` 경로에 포함한다. Local machine path 없이 파일을 찾을 수 있다. Criterion-validity access ledger에는 seed reveal 1회와 result evaluation 1회가 기록되어 있다.

Freeze 값

40d3d2083601f1214e2f26fc9833d22e97d369e3c6471646a3b5390124dc972f

은 `artifact_gate.json`과 access ledger 내부에 선언된 combined digest다. 두 container file 중 하나의 SHA-256이 아니다. 이전 manifest, raw-result, analysis 및 report digest 문자열도 internal payload digest였다. 따라서 이 self-declared field를 독립 무결성 검증으로 사용하지 않는다.

대신 전달 파일 자체의 직접 SHA-256은 다음과 같다.

```
manifest:
0ec0b96685828d84432216a5bc7e10ddccd6f293963f6975117d3d698523c189
raw result:
3d6c69af546e311fb15c0c8e521e776eb79a9ba88dc6389e5457c45325b4e734
confirmatory analysis:
2cb260a084a6c6175e6b5312bcb32a6dcadafd16035f6c2123abc08c0fe3da0b
evidence report:
43d5643c95ecb5cb9268d2f57ccfce19214dc18392e31f399ddd993b01816211
access ledger:
8c8651cef755a2a3c8a9be5bf3ddc3a86af382721369cc72902c783fb8fe144b
scope audit:
f6151ca50dfdbe50e23558b6f18a9325300bae8c695d52df4145a3d3a6110ab9.
```

위에서 열거한 historical file 여섯 개는 package-relative `experiments/ tree`에 포함하며 reviewer-response README가 각 label과 file을 연결한다. Bundle-level SHA256SUMS는 전달 파일 전체를 독립적으로 포괄한다. Final scope audit는 historical superseded artifact로 보존할 뿐 현재 grade 부여에 사용하지 않는다.

Cumulative “evidence level”은 부여하지 않는다. 이 논문에서 완료된 의무는 위에서 설명한 sealed OOD, sealed rollout, same-task criterion, failure preservation 및 artifact integrity 검사로 한정된다. 별도 supporting artifact가 algorithmic graph discovery, bounded noisy perception, variable cardinality, packaged benchmark runner와 두 번째 finite mechanism family를 다루지만, 이를 learned neural structure discovery, public-domain validation 또는 independent replication으로 변환하지 않는다.

Packaged runner는 `PYTHONPATH=src python3 tools/run_paper3_public_benchmark.py`다. 기존 byte-identical output 두 개는 deterministic same-environment replay만 확립한다. Prospective extension은 project import가 0인 별도 Node.js 구현을 추가했다. 이 구현은 공개된 seed commitment를 검증하고 learned graph-head fit 120/120개와 analysis mean 10/10개를 재현했다. Freeze, raw result, analysis, integrity ledger, portable input, clean-room audit 및 JavaScript source의 직접 SHA-256은 각각 `bfdc91ec3156`, `cd89c1ff6055`, `2e6880df0543`, `e0ca28d93c7c`, `3f438a1cfb7d`, `8371860c58c8`, `b648562bc3b8`이다. 이 path는 export한 world data를 사용하며 committed seed에서 world를 다시 유도하지 않는다. 따라서 generator-side error와 world-seed derivation은 검증 범위 밖이다. 별도 Python derivation audit는 보관한 frozen generator로 revealed root에서 seed 120개를 유도하고 모든 train, selection 및 test case를 재생성하여 portable export와 discrepancy 없이 일치시킨다. 이는 frozen Python implementation 내부의 seed/export consistency를 검증하며 second-language generator replication은 아니다. 영문/한국어 section 구조, mathematical environment, decimal literal 및 rendered text regression을 함께 검사한다.

10 결론

기존 exact-state 연구는 sealed OOD와 open-loop routing effect 및 더 좁은 four-arm same-task criterion association을 확립했다. Arm-level decomposition은 pooled criterion estimand가 routing correctness를 식별할 수 없음을 정확히 보였다.

Prospective stochastic 연구는 기존 결과의 명칭을 바꾸지 않고 그 identification 문제를 해결한다. 서로 겹치지 않는 noisy training 및 selection partition에서 routing과 head family를 학습했다.

이어 120개 fresh world에서 correct learned routing은 shifted route보다 composition NLL, six-step rollout error와 시간 순서가 보장된 criterion Brier score를 개선했다. 결과는 원래 linear transition 식 밖에서도 유지됐고 clean-room Node.js 구현이 learned fit과 analysis mean을 재현했다.

따라서 결론은 다음과 같이 정확하다. 선언한 finite stochastic family 안에서 train-only structural identification은 active two-edge mechanism을 회수하며, 그 mechanism의 correct routing은 predictive 및 criterion value를 갖는다. Visual perception, unconstrained neural discovery 또는 real-world system은 서로 다른 estimand이므로 본 결론에 붙은 미해결 조건으로 주장하지 않는다.

References

- [1] Mahmoud Assran, Quentin Duval, Ishan Misra, Piotr Bojanowski, Pascal Vincent, Michael Rabbat, Nicolas Ballas, and Yann LeCun. Self-supervised learning from images with a joint-embedding predictive architecture. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 15619–15629, 2023. doi: 10.1109/CVPR52729.2023.01499.
- [2] Adrien Bardes, Quentin Garrido, Jean Ponce, Xinlei Chen, Michael Rabbat, Yann LeCun, Mahmoud Assran, and Nicolas Ballas. V-JEPA: Latent video prediction for visual representation learning. *arXiv preprint arXiv:2404.08471*, 2024. doi: 10.48550/arXiv.2404.08471.
- [3] Gary S. Collins, Karel G. M. Moons, Paula Dhiman, Richard D. Riley, Andrew L. Beam, Ben Van Calster, Marzyeh Ghassemi, Xiaoxuan Liu, Johannes B. Reitsma, Maarten van Smeden, and Anne-Laure Boulesteix. TRIPOD+AI statement: Updated guidance for reporting clinical prediction models that use regression or machine learning methods. *BMJ*, 385:e078378, 2024. doi: 10.1136/bmj-2023-078378.
- [4] Tilmann Gneiting and Adrian E. Raftery. Strictly proper scoring rules, prediction, and estimation. *Journal of the American Statistical Association*, 102(477):359–378, 2007. doi: 10.1198/016214506000001437.
- [5] Sture Holm. A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, 6(2):65–70, 1979.
- [6] Thomas Kipf, Elise van der Pol, and Max Welling. Contrastive learning of structured world models. In *International Conference on Learning Representations*, 2020. URL <https://openreview.net/forum?id=H1gax6VtDB>.
- [7] Facundo Mémoli. Gromov–wasserstein distances and the metric approach to object matching. *Foundations of Computational Mathematics*, 11(4):417–487, 2011. doi: 10.1007/s10208-011-9093-5.
- [8] Judith D. Singer and John B. Willett. It’s about time: Using discrete-time survival analysis to study duration and the timing of events. *Journal of Educational Statistics*, 18(2):155–195, 1993. doi: 10.3102/10769986018002155.
- [9] Sudhir Varma and Richard Simon. Bias in error estimation when using cross-validation for model selection. *BMC Bioinformatics*, 7:91, 2006. doi: 10.1186/1471-2105-7-91.

- [10] Titouan Vayer, Laetitia Chapel, Rémi Flamary, Romain Tavenard, and Nicolas Courty. Fused gromov–wasserstein distance for structured objects: Theoretical foundations and mathematical properties. *Algorithms*, 13(9):212, 2020. doi: 10.3390/a13090212.