

TSI 전이 모형에서 graph information과 head factorization의 prospective 귀속

하철수

개정일: 2026년 8월 20일

Abstract

이전 288-cell benchmark는 exact representability를 확립할 수 있었지만 TSI predictor가 generating equation이었으므로 graph information과 head form을 분리하지 못했다. 본 논문은 그 audit를 보존하고, source 동결, fresh 256-bit seed 생성과 one-shot 실행을 하나의 scripted sequence에서 그 순서대로 수행한 새로운 prospective 연구를 보고한다. 무결성은 경과 시간 간격이 아니라 frozen hash와 seed commitment에서 나온다. 이 연구는 30개 two-edge graph motif와 세 head family를 교차하며, 두 family는 원래 linear TSI 식 밖에 있다. 두 mechanism을 동시에 활성화하는 stochastic two-coordinate action은 평가용으로 남겼다. 120개 independent world 모두에서 train-only selection이 graph와 두 head family를 회수했다(multiplicity-adjusted Wilson 하한 0.941). Correct-minus-wrong graph NLL effect는 seven-parameter factorized head에서 0.35933, seven-parameter generic sparse head에서 0.36160, 55-parameter dense modular head에서 0.03893이었고 simultaneous 하한은 모두 양수였다. Correct graph 아래 factorized head와 generic seven-parameter head는 predictive-equivalent였다. Seven-sparse embedding은 이 동틀을 가능하게 하고, sparse procedure는 모든 world에서 동등한 support를 회수했다. 이 cohort, root seed와 여덟-quantity multiplicity family는 Paper 3과 공유한다. 두 논문의 겹치는 endpoint는 하나의 frozen analysis에 속하며 독립 evidence가 아니다. 또한 full-support primitive intervention과 symmetric coordinate corruption $p < 6/7$ 아래 population motif 식별가능성을 finite repeated-input recovery bound와 함께 증명한다. Post-review 3×3 noise sweep의 모든 cell에서 graph-head 회수율 1.000이 유지됐다. Outside-family 성능은 원래 linear family에 noninferior했다. 두 번째 frozen cohort에서는 unmodeled nonadditive synergy가 120/120개 world의 exactness를 깨뜨렸지만 learned-versus-wrong graph NLL effect 0.18545 [0.18388, 0.18702]를 보존했다. Clean-room Node.js 구현은 learned fit 120/120개와 analysis mean 10/10개를 재현했다. 식별된 기여는 graph information과 minimal typed support의 회수이며, 동일 support를 회수한 generic head 대비 factorized notation만의 고유 predictive advantage가 아니다.

1 서론

TSI는 internal transition model이 모든 state coordinate를 관계없는 수치로 취급하기보다 선언된 structural dependency를 표현해야 한다고 제안한다. Paper 3의 historical standalone 연구는 다른 simulator에서 sealed structural OOD, open-loop rollout과 same-task criterion association을 평가한다. 이 연구들은 여기서 다루는 exact factorization을 확립하지 않고 historical Paper 4 audit의 quantity를 추정하지 않으며 서로의 replication도 아니다. 그러나 Paper 3의 새 prospective extension은 본 논문의 attribution cohort다. Root seed와 multiplicity family를 공유하며 겹치는 endpoint는 독립 evidence가 아니다.

이 benchmark의 원래 질문은 discovered structural factorization이 diagonal 또는 unstructured control보다 held-out intervention을 잘 예측하는지였다. 이 표현은 너무 강하다. Finite generator가 TSI hypothesis class 안에 있고 fitted TSI predictor는 동일한 transition equation을 사용한다. Graph와 여섯 parameter를 유일하게 회수하면 exact prediction은 분석적으로 따라온다. 따라서

primary audit는 factorization의 empirical causal effect가 아니라 exact representability와 finite-family identifiability를 다룬다.

Structural prediction에는 raw observation에서 entity discovery, 시간에 걸친 identity, relation, structural variable과 dependency graph를 거쳐 prediction에 이르는 chain이 필요하다. 본 연구는 이 chain의 후반 단계를 다룬다. Entity set과 cross-time identity는 generator가 제공하며, 이들이 주어진 뒤의 graph recovery와 prediction을 검정한다. Raw observation에서 entity를 발견하고 그 identity를 유지하는 문제는 이 audit의 estimand 밖에 있다.

Frozen comparison은 투명한 기록으로 유지하고, 명확히 표시한 post-review diagnostic을 추가한다. 이 확장은 cell-level average가 tie와 structural zero를 어떻게 가리는지, graph choice의 효과가 factorized head와 untied dense head에서 같은지, 그리고 실제 two-coordinate action 또는 fitted TSI family 밖 transition term에서 exactness가 어디서 실패하는지를 묻는다. 이 diagnostic은 universal model-superiority claim을 복권하지 않고 attribution boundary를 드러낸다. 이어지는 prospective 연구는 fresh stochastic family, complete graph-by-head design, matched seven-parameter control, learned routing, genuine two-mechanism composition, multiplicity-adjusted world-level inference와 second-language implementation으로 확인된 design defect를 해결한다.

2 관련 연구와 범위

개입을 이용한 인과 구조 학습. 관찰 자료만을 이용한 DAG 발견은 일반적으로 Markov 동치류의 제약을 받지만, 알려진 개입은 동치류를 세분화하며 추가 조건 아래에서 그래프를 더 많이 식별할 수 있다 [8, 19]. 점수 기반 방법과 연속 최적화 방법은 개입 greedy equivalence search부터 개입 우도를 이용하는 미분 가능한 최적화까지 포함한다 [6, 20]. 본 연구의 과제는 이보다 훨씬 좁다. 다섯 좌표와 개입 표적을 모두 관측하고, 후보 그래프는 유한한 typed motif 족이며, 자료 생성기는 선언된 전이 언어 안에 있다. 따라서 120-world 결과는 이 유한 족 안의 회수에 대한 증거이지, 일반 DAG 발견 결과도 아니고 관찰 자료에서의 인과 식별 주장도 아니다.

인과 표현학습. 인과 표현학습은 고차원 혼합으로부터 잠재 인과 변수와 그 관계를 언제 회수할 수 있는지를 다룬다 [14]. 개입을 이용한 기존 결과들은 완전 개입, 불완전 개입, 표적을 모르는 개입, uncoupled 개입, 다중 노드 개입에 서로 다른 가정을 두고 식별가능성을 제시한다 [1, 5, 16, 17]. 반면 본 연구는 잠재 좌표나 지각 혼합 함수를 추론하지 않는다. modular 좌표, action 표적, action 크기가 주어진다. 본 연구의 기여는 이러한 표현 변수가 이미 선언된 뒤 graph 선택과 typed head factorization의 기여를 통제된 조건에서 귀속하는 데 있다.

최소 support 회수. ℓ_1 방법과 greedy pursuit의 정확한 support 회수는 설계, 신호, 잡음, incoherence 또는 restricted-curvature 조건에 의존하는 것으로 알려져 있다 [2, 7, 15, 18]. 여기서 사용하는 seven-sparse embedding은 선형 Gaussian Lasso나 orthogonal matching pursuit 문제가 아니라 $\mathbb{Z}_7$ 위의 대수적 표현이다. 본 논문의 population 명제는 full-support primitive intervention 아래 유한 motif를 식별하고, repeated-input 따름정리는 좌표별 최빈값 오류를 제어한다. 어느 결과도 구현된 greedy selector의 유한 random-design 회수를 증명하지 않으므로, 120/120 회수율은 경험적 결과로 남는다.

구조화 world model. Interaction network와 graph network는 객체와 관계 구조를 구조적 귀납 편향으로 부호화한다 [3, 4]. Neural relational inference, contrastive structured world model, slot 기반 객체 발견, 구조화 탐색은 서로 다른 복잡도의 관측으로부터 그래프 또는 객체 중심 동역학을 학습한다 [9–11, 13]. TSI의 유한 modular world는 더 구체적인 질문을 위한 시험대이다. 즉, 선언된 의존 정보와 transition-head factorization이 통제된 OOD 개입에서 각각 측정 가능한 기여를 하는지

를 묻는다. 현재 증거는 시각적 객체 발견, 확장 가능한 graph-neural dynamics, 실제 세계 타당성을 확립하지 않는다.

모듈성과 독립 메커니즘. independent causal mechanisms 원리는 자료 생성 과정을 자율적인 모듈로 분해할 동기를 제공하며, 기존 연구는 변환된 도메인에서 이러한 메커니즘을 학습하고자 했다 [12]. 본 논문의 graph-by-head 요인 설계는 그중 제한된 유사물만 조작화한다. prediction head가 올바르게 factorized되거나, untied dense이거나, 의도적으로 불일치할 때에도 routing 정보가 기여하는지를 검정한다. 따라서 보고한 interaction과 stress-cohort 결과는 benchmark 내부의 구성 요소 귀속 경계를 정할 뿐, 독립 메커니즘의 보편적 자율성이나 발견을 입증하지 않는다.

3 감사 계약과 방법

3.1 Finite family와 analytic representability

Family는 cardinality (4, 3, 5, 3, 4)인 다섯 finite state coordinate, 세 directed dependency graph와 96 multiplier/coupling mechanism으로 구성되어 288개 graph-mechanism cell을 만든다. Graph edge $s \rightarrow r$ 에서 generator는

$$x'_j = [x_j + m_j a_j + \mathbf{1}\{j = r\} c a_s (1 + x_r)]_{q_j}$$

이다. Fitted TSI head는 training transition에서 graph, $(m_1, \dots, m_5)$, c 를 회수한 뒤 같은 equation을 적용한다. Candidate graph는 training partition에서만 scoring하며 training exact accuracy 1.000인 candidate가 유일할 때만 accept한다. 따라서 recovery가 성공하면 exact test prediction은 보장된다. Recovery에 조건화한 accuracy 1.000은 stochastic discovery가 아니다.

Training action은 magnitude-1 one-hot vector 다섯 개다. 원래 test partition은 held-out primitive source-action pair와 단일 좌표 magnitude-2 action 두 개 (0, 2, 0, 0, 0), (0, 0, 2, 0, 0)를 추가한다. 이들은 two-coordinate composition이 아니라 scale extrapolation이다. 720개 state 전체에서 cell당 1,440개 intervention case를 만든다. Train/test source-action key 중복은 0이고, 기록된 split audit, train-only discovery audit, test-only evaluation audit와 source inspection check는 모두 통과했다.

3.2 Frozen control과 unit

Diagonal model은 coordinate 별 action multiplier를 추정한다. Graph-unaware dense polynomial model은 intercept, state value 다섯 개, action value 다섯 개와 25개 source-action interaction을 사용하고 least squares로 fit한다. Lookup model은 training source-action pair를 암기한다. Wrong-routed model은 shifted graph에서 factorized equation을 적용한다. Independent unit은 graph-mechanism cell이다. 다섯 row-permutation seed는 trainable control 내부에 nested되어 cell 안에서 평균하며 TSI, wrong-routed, lookup은 deterministic fit 하나를 사용한다. 원래 descriptive contrast는 TSI minus graph-unaware dense intervention accuracy다.

3.3 Post-review diagnostic

다음 analysis는 peer review 뒤 설계했으며 preregistered confirmatory test가 아니다.

첫째, graph-by-head panel은 correct/shifted graph와 modular factorized/untied multi-output least-squares head를 교차한 네 operational cell을 채운다. Dense head는 intercept, 다섯 action value와 graph-selected term $a_s(1 + x_r)$ 를 사용하며 output coefficient를 generator parameter에 tie하지 않는다. 이는 명시적 dense-head operationalization 하나이지 모든 dense model의 보편적 class가 아니다.

둘째, genuine composition panel은 서로 다른 두 active coordinate를 가진 binary action $\binom{5}{2} = 10$ 개, 즉 cell당 7,200 case를 검사한다. 셋째, misspecified panel은 fitted action-linear TSI equation에 없는 target term

$$a_s(a_s - 1)(1 + x_r)$$

을 추가한 뒤 단일 좌표 magnitude-2 action 다섯 개를 검사한다. 이 term은 모든 magnitude-1 training action에서 0이므로 원래 training partition과 recovery procedure는 바뀌지 않지만 test time에는 fitted TSI equation 밖에 있다. 이 panel은 cell당 3,600 case를 포함한다.

Frozen audit는 experiments/paper4_final_comparative_audit.json, 확장은 experiments/paper4_postreview_diagnostics.json에 저장했다. 교정한 cell distribution과 budget/replay declaration은 paper4_statistical_analysis_r2.json 및 paper4_fairness_audit_r2.json에 저장했다.

3.4 Prospective 귀속 contract

Diagnostic 뒤 새 contract와 implementation을 동결하고 나서 fresh confirmatory seed를 생성했다. 동결, seed 생성과 one-shot 실행은 하나의 scripted sequence에서 그 순서대로 진행했다. 순서 보장은 경과 시간이 아니라 frozen source hash와 seed commitment에서 나온다. 각 world는 modulo 7인 다섯 coordinate와 서로 다른 두 source가 하나의 target으로 들어가는 graph motif를 갖는다. Motif는 30개다. 각 edge는 다음 세 typed function 중 하나를 사용한다.

$$\phi_L = a_s(1 + x_t), \quad \phi_Q = a_s(1 + x_t)^2, \quad \phi_S = a_s(1 + x_s + x_t).$$

뒤의 두 function은 원래 linear equation 밖에 있다. Training과 selection은 서로 겹치지 않는 noisy primitive-action transition 800개와 400개를 포함한다. OOD case 1,200개에는 active coordinate가 두 개 있으며 사전지정 stratum은 두 graph source를 모두 활성화하여 두 mechanism을 composition한다. Coordinate noise는 OOD 평가에서 0.08에서 0.12로 증가한다.

Complete attribution panel은 correct/shifted graph를 세 head operationalization과 교차한다. Factorized head는 direct multiplier 다섯 개와 typed edge coefficient 두 개를 갖는다. Generic sparse modular head는 다섯 direct action 및 declared edge마다 세 function을 포함한 dictionary에서 output-feature coefficient 일곱 개를 greedily 선택한다. Dense sensitivity는 $5 \times 11 = 55$ 개 modular coefficient를 coordinate descent로 적합한다. 따라서 factorized와 sparse-generic cell은 active parameter count가 일곱 개로 같고 dense cell은 generic head에 더 큰 capacity를 준다.

명제 1 (Seven-sparse embedding). 고정 graph와 선택한 edge family에서 prospective family의 모든 seven-parameter factorized transition은 정확히 동등한 seven-sparse generic modular head를 가진다.

Proof. 각 coordinate j 에 대해 output j 의 direct feature a_j 에 generic coefficient m_j 를 할당하면 nonzero coefficient 다섯 개를 얻는다. 공통 target t 에서 edge e 의 선택된 feature ϕ_{f_e} 에 coefficient c_e 를 할당하면 두 개가 더해진다. 나머지 coefficient는 모두 0으로 둔다. 그러면 generic increment는

$$\delta_j = m_j a_j + \mathbf{1}\{j = t\} \sum_{e=1}^2 c_e \phi_{f_e}$$

가 되어 coordinate 별로 factorized increment와 같다. x_j 를 더하고 modulo 7로 줄여도 등식은 보존된다. 역으로 generic support를 이 일곱 위치로 제한하면 동일한 factorized equation을 얻는다. $\square$

명제 2 (Population motif 식별 가능성). $\mathbb{Z}_7^5$ 위의 prospective family를 생각하자. Primitive intervention distribution이 모든 state x 와 unit action e_s 에 full support를 갖고, 모든 multiplier와 edge coefficient가 $\{1, 2, 3\}$ 에 속하며, 각 successor coordinate가 독립적으로 확률 $1 - p$ 에 유지되고 확률

$p < 6/7$ 에 나머지 여섯 값 중 하나로 균등하게 바뀐다고 하자. 그러면 (x, e_s, x') 의 *joint population distribution*은 *common-target two-source motif*, 각 *source*에 연결된 *ordered head family*와 일곱 *parameter*를 유일하게 식별한다.

Proof. Input과 deterministic center value에 조건화하면 center의 확률은 $1 - p$ 이고 다른 각 값의 확률은 $p/6$ 이다. $p < 6/7$ 은 $1 - p > p/6$ 과 동치이므로 center는 유일한 conditional mode다. 따라서 population distribution은 전체 deterministic primitive-action transition map을 식별한다.

Action e_j 에서 output coordinate j 는 m_j 만큼 변한다. j 에서 시작하는 edge는 j 와 다른 target coordinate만 바꾼다. 따라서 direct multiplier 다섯 개가 식별된다. 이 direct increment를 뺀 뒤, nontarget coordinate의 primitive action이 다른 coordinate에 nonzero residual을 만드는 state가 존재할 필요충분조건은 그 action coordinate가 graph source인 것이다. 실제로 선언한 각 edge feature는 어떤 state에서 0이 아니고 coefficient도 0이 아니다. 따라서 full state support는 이러한 residual family 두 개를 받는 유일한 output과 두 source를 식별한다.

이제 각 source의 family와 coefficient를 식별하면 된다. Source-target feature $\phi_S = 1 + x_s + x_t$ 는 x_s 에 의존하지만 $\phi_L = 1 + x_t$ 와 $\phi_Q = (1 + x_t)^2$ 는 의존하지 않으므로, full support에서 ϕ_S 는 두 대안 중 어느 것의 nonzero multiple과도 같을 수 없다. 모든 x_t 에서 $c\phi_L = c'\phi_Q$ 라면 $x_t = 0$ 을 대입해 $c = c'$ 를 얻는다. $x_t = 1$ 을 대입하면 $\mathbb{Z}_7$ 에서 $2c = 4c$, 따라서 $c = 0$ 인데 이는 $c \in \{1, 2, 3\}$ 와 모순이다. 그러므로 family는 유일하다. $x_s = x_t = 0$ 에서는 선택한 모든 feature가 1이므로 residual이 해당 coefficient를 식별한다. 따라서 모든 구성요소가 유일하다. $\square$

따름정리 1 (반복 input 회수 경계). 앞의 증명에 충분한 *primitive input-output coordinate pair*의 *finite separating set*을 $\mathcal{I}$ 라 하고, 각 *pair*의 *input*을 적어도 n 회 독립 반복한다고 하자. $\mathcal{I}$ 위의 *modal reconstruction*과 그에 따른 *motif* 식별이 실패할 확률은 다음 이하이다.

$$6|\mathcal{I}| \exp \left[-\frac{n}{2} \left(1 - \frac{7p}{6} \right)^2 \right].$$

Proof. 고정 input, center value 및 wrong value 하나에 대해 center indicator에서 wrong-value indicator를 뺀다. 이 변수는 $[-1, 1]$ 에 있고 기댓값은 $(1 - p) - p/6 = 1 - 7p/6 > 0$ 이다. Hoeffding inequality는 wrong empirical count가 center count 이상일 확률을 $\exp[-n(1 - 7p/6)^2/2]$ 로 제한한다. 여섯 wrong value와 $\mathcal{I}$ 의 모든 pair에 union bound를 적용하면 위 경계를 얻는다. 모든 modal center가 정확하면 Proposition 2가 유일성을 보장한다. $\square$

이 결과는 population/full-support 명제와 repeated-input bound이며, finite random-design greedy selector가 반드시 motif를 회수한다는 증명이 아니다. 120/120 회수율은 별도의 empirical result로 남는다.

Independent unit은 world다. Confirmatory cohort는 120개 world이며 familywise level 0.05에서 여덟 inferential quantity에 Bonferroni simultaneous interval을 사용한다. Primary graph effect는 각 head 안의 wrong-minus-correct NLL이다.

Analysis object는 frozen Bonferroni divisor 8로 interval-bearing quantity 열 개를 보고한다. 여기에는 exact duplicate pair 하나, sign-flipped pair 하나와 deterministic zero 하나가 있어 정보적으로 구별되는 stochastic quantity는 일곱 개다. Frozen v1 contract는 정수 divisor만 지정하고 구성원을 열거하지 않았다. 이는 reporting defect이며 사전등록된 family 정의가 아니다. 현재 code는 identification, learned-routing NLL, factorized-graph NLL, generic-graph NLL, dense-graph NLL, rollout Hamming, criterion Brier 및 outside-family noninferiority를 여덟 gate quantity로 열거되 post-freeze clarification임을 명시한다. Post-review sensitivity에서 divisor 10을 사용해도 모든 decision은 유지된다. 이 cohort, root seed와 multiplicity family는 Paper 3과 공유한다. 두 논문의 접치는 endpoint는 하나의 frozen analysis 중 일부이며 독립 evidence가 아니다.

Confirmation 전에 120개 world에 대한 power analysis를 동결하지 않았다. Post-review retrospective design justification은 development world 24개만 사용하고 original 및 outside-linear family로 증화한다. Bootstrap 20,000회에서 120개 world의 nine-gate conjunctive power 추정치는 0.9694, Monte Carlo interval은 [0.9670, 0.9718]이다. Development-fitted calibration을 고정값으로 취급하고 24개 world의 empirical support를 그대로 상속한다. 이는 preregistration record도 frozen design의 소급 변경도 아니다.

3.5 Prospective outside-model-family stress contract

두 번째 source freeze 뒤 별도 120-world seed를 생성했다. Held-out successor는 graph target에 다음항을 더한다.

$$d a_{s_1} a_{s_2} (1 + x_u)$$

여기서 u 는 target이나 두 source가 아니고 $d \in \{1, 2, 3\}$ 이다. 이 nonadditive synergy는 모든 primitive training 및 selection action에서 0이며 fitted dictionary 어디에도 없다. 두 mechanism에 동시에 intervention할 때만 활성화된다. Frozen gate는 모든 world의 learned prediction이 nonexact일 것과 wrong-minus-learned NLL mean이 0.03 이상이면서 95% 하한이 양수일 것을 요구한다.

4 결과

4.1 Frozen exact-family audit

Table 1은 전체 288-cell audit를 보고한다. TSI가 exact인 이유는 recovered predictor가 generating equation이기 때문이며, test가 일반적 learning advantage를 식별했기 때문이 아니다.

Table 1: Frozen finite-family audit.

Model	Exact accuracy	Intervention accuracy
TSI graph-discovered factorized	1.000	1.000
Dense polynomial trainable	0.622	0.413
Diagonal trainable	0.605	0.410
Wrong-routed factorized	0.234	0.200
Unstructured lookup	0.000	0.000

Average는 중요한 cell structure를 가린다. Dense intervention accuracy는 33개 cell에서 exact이고 32개 cell에서 0이다. 따라서 288개 TSI-minus-dense cell difference가 모두 양수인 것은 아니다. Wrong-routed accuracy는 192개 cell에서 정확히 0, 96개 cell에서 0.6이며 lookup은 288개 cell 모두 0이다. 따라서 wrong routing은 graph-dependent support point를 보이며, sparsity만으로 불충분하다는 generic test가 아니다. Lookup은 competitive representation learner가 아니라 의도적으로 input-disjoint인 structural zero다.

다섯 repeated trainable row를 cell 안에서 평균한 뒤 finite-panel mean TSI-minus-dense intervention contrast는 0.587이다. Paired cell bootstrap interval은 [0.549, 0.624], corresponding all-case contrast는 0.378과 [0.354, 0.401]이다. 이 interval은 열거된 cell 사이 variation을 요약할 뿐 super-population을 정의하거나 analytic exact-representability confound를 제거하지 않는다.

4.2 Post-review diagnostic panel

Table 2은 mean cell accuracy를 보고한다. 모든 model은 원래 primitive-action training partition에서만 fit했다.

Table 2: Post-review descriptive diagnostic. “Original”은 단일 좌표 magnitude-2 action 두 개, “Composition”은 two-coordinate binary action 열 개, “Misspecified”는 unmodeled action curvature를 사용한다.

Model	Original	Composition	Misspecified
Correct graph, factorized head	1.000	1.000	0.869
Wrong graph, factorized head	0.200	0.227	0.413
Correct graph, dense head	0.268	0.285	0.231
Wrong graph, dense head	0.501	0.463	0.485
Graph-unaware dense	0.413	0.426	0.392

실제 two-coordinate panel은 independent discovery를 제공하지 않는다. Generator와 TSI head가 모두 action-linear 이므로 exact superposition은 분석적으로 합의된다. 다만 이전 intervention description을 바로잡는다. Unmodeled curvature term 아래 TSI accuracy는 0.868889로 내려가고 288개 cell 중 exact cell은 하나도 없다. 따라서 exactness는 선언한 hypothesis family 밖에서 robust하지 않다. 해당 panel에서 post-review TSI-minus-graph-unaware-dense difference는 양수지만 preregistered가 아니며 그 자체로 universal advantage를 식별하지 않는다.

Graph-by-head panel도 단순 귀속을 거부한다. Original action에서 correct-minus-wrong graph accuracy는 factorized head에서 0.800이지만 지정한 dense head에서는 -0.233이다. Factorized-minus-dense-head accuracy는 correct graph에서 0.732, wrong graph에서 -0.301이다. 이 반전은 operational definition에 묶인 graph-head interaction을 보인다. Head-independent graph effect도 graph-independent factorization effect도 없다. 이 diagnostic 반전은 해당 least-squares head, exact-family generator와 accuracy endpoint에 한정된다. Prospective stochastic family와 modular dense head에서는 graph NLL effect가 양수다.

4.3 Prospective 귀속 결과

Train-only selection은 120/120개 world에서 motif와 두 head family를 회수했고, multiplicity-adjusted Wilson 하한은 0.941이었다. 표 3은 complete graph-by-head 결과를 제시한다.

Table 3: Wrong-minus-correct graph composition NLL. 양수는 correct graph에 유리하다.

Head	Parameters	Mean	Simultaneous interval
Factorized typed	7	0.35933	[0.35431, 0.36435]
Generic sparse	7	0.36160	[0.35683, 0.36637]
Generic dense	55	0.03893	[0.02527, 0.05259]

Graph information은 higher-capacity dense sensitivity를 포함한 세 head operationalization 모두에서 positive effect를 가진다. Correct graph에서 factorized-minus-generic-sparse NLL은 모든 world에서 정확히 0.00000이다. 두 seven-parameter head의 graph-by-head interaction은 -0.00227, simultaneous interval은 [-0.00822, 0.00368]이다. 명제는 exact predictive tie를 설명한다. 두 fitted procedure가 동일한 seven-term function을 회수한다. 따라서 evidence는 성능을 correct graph information과 minimal-support recovery에 귀속하며 factorized notation 자체의 irreducible advantage에 귀속하지 않는다.

이 등가성은 조건부다. Generic dictionary가 선택된 edge 함수를 포함하고 selector가 그 support를 회수해야 성립한다. Dictionary가 오 설정되었거나 주어진 표본 크기와 잡음 수준에서 support가 회수되지 않는 영역에서는 typed factorization이 generic head와 등가가 아니다. 그 영역은 본 연구에서 시험되지 않았으며, typed structure의 고유 기여를 찾는다면 그곳이 자연스러운 출발점이다.

Nonlinear head를 하나 이상 사용한 80개 world는 원래 linear world 40개에 noninferior했다. NLL difference는 -0.00132, simultaneous interval은 [-0.01031, 0.00766]으로 frozen margin 0.03보다 작았다. Attribution 및 연결된 Paper 3 gate 아홉 개가 모두 통과했다.

별도 post-review descriptive sensitivity는 train noise 0.04, 0.08, 0.16과 OOD noise 0.06, 0.12, 0.24를 교차했다. 아홉 cell마다 public-seed world 120개를 사용했다. Graph와 head 회수율은 모든 cell에서 1.000이었다. Grid 전체의 minimum mean wrong-minus-correct NLL effect는 factorized head 0.23337, generic sparse head 0.23773, generic dense head 0.02420이었고, 가장 작은 dense-head descriptive 95% 하한은 0.01719였다. 이 panel은 confirmatory가 아니며 coordinate-corruption noise 만 변화시킨다.

4.4 Outside-model-family stress 결과

Nonadditive synergy는 fresh world 120개 모두에서 exact learned prediction을 깨뜨렸다. Both-mechanisms stratum의 mean noiseless center accuracy는 0.14104였다. 그럼에도 wrong-minus-learned stochastic composition NLL은 0.18545, world SD는 0.00879, 95% interval은 [0.18388, 0.18702]이었다. 따라서 exact representability를 의도적으로 제거한 뒤에도 graph effect가 남는다. Synergy는 모든 training 및 selection case에서 0이었고 frozen stress gate 네 개가 모두 통과했다.

Python project를 import하지 않는 Node.js 구현이 attribution world 120개 모두의 learned model과 NLL value를 독립적으로 회수하고 published analysis mean 열 개를 재계산했다. 공개된 root-seed commitment도 검증했으며 discrepancy는 없었다.

별도 Python audit는 revealed root에서 world seed 120개를 유도하고 보관한 frozen generator로 export된 모든 train, selection 및 test transition을 재생성했다. 모든 case가 portable input과 일치했다. 이는 frozen Python path 내부의 seed derivation과 export consistency를 해결하지만 Node.js analysis를 독립 generator implementation으로 바꾸지는 않는다.

4.5 이 audit이 확립하는 것과 확립하지 않는 것

Table 4: 확립된 claim의 범위.

확립됨	확립되지 않음
World 120/120에서 train-only graph와 head 회수	동일한 support를 회수하는 generic head 대비 factorized <i>notation</i> 의 우위
세 head operationalization 모두에서 correct graph가 held-out two-mechanism composition NLL을 개선	Raw observation에서 entity discovery 또는 identity maintenance
Exact representability를 의도적으로 제거한 뒤에도 graph effect가 유지됨 (0.18545, 120/120 world nonexact)	Correct minimal support를 넘어서는 richer structural state의 추가 가치
동일한 support를 회수하면 factorized head와 matched generic sparse head가 정확히 동등함	Real-world, neural, continuous 또는 perceptual validity

5 범위

Historical exact-family 및 retrospective diagnostic 결과는 원래 해석을 유지하며 prospective evidence로 계산하지 않는다. 새 cohort 두 개는 서로 독립인 fresh seed, source freeze, one-shot lock과 world-level inference를 사용한다.

Prospective population은 finite synthetic population이다. 다섯 modular coordinate, 30개 two-edge motif, 세 declared additive head family, 한 unmodeled synergy form과 지정한 coordinate noise

로 구성된다. 결론은 이 population을 정량화한다. Visual, continuous, neural 또는 real-world system은 estimand에서 sampling되지 않으므로 sparse model의 universal superiority나 이들 system에 대한 claim을 함의하지 않는다.

Seven-parameter 동틀은 failed comparison이 아니라 positive structural result다. 명제는 generic procedure가 동일 support를 회수하면 factorized head와 generic head가 functionally identical함을 보인다. Empirical distinction은 support 및 graph recovery다. 55-parameter dense sensitivity도 더 작지만 positive graph effect를 유지하므로 결과가 matched sparsity만으로 만들어진 것은 아니다.

Clean-room Node.js path는 Python project를 import하지 않고 graph/head search, factorized fitting, NLL evaluation과 analysis mean을 독립 구현한다. 이는 동일 investigator가 수행한 implementation replication이지 between-laboratory variation에 대한 evidence는 아니다. 이 authorship 사실은 여기서 주장하는 computational reproducibility를 바꾸지 않는다. 이 path는 export한 world data를 사용하며 committed seed에서 world를 다시 유도하지 않는다. 따라서 generator-side error와 world-seed derivation은 검증 범위 밖이다. 별도 Python derivation audit가 선언한 seed rule과 전체 export를 보관한 frozen generator에 대조하지만 동일 language와 code lineage 안에 남는다. Independent laboratory replication은 주장하지 않는다.

6 결론

원래 288-cell audit는 exact representability를 확립했지만 generating equation, graph information과 head form을 교란했다. Retrospective diagnostic은 그 defect를 드러냈지만 해결하지는 못했다.

새로 동결한 prospective cohort 두 개가 이를 해결한다. Attribution cohort에서는 train-only selection이 stochastic noise 아래 two-edge graph와 head family를 회수했다. Correct graph information은 factorized, parameter-matched generic sparse 및 더 큰 dense head 모두에서 held-out two-mechanism composition NLL을 개선했다. Seven-sparse embedding 명제는 동등한 generic support의 존재를 확립하며, sparse procedure가 모든 world에서 그 support를 회수하여 factorized head와 정확한 동틀을 만들었다. 따라서 고유한 대상은 surface notation이 아니라 typed minimal support와 그 learned graph다.

Population 결과는 full-support primitive intervention과 6/7 미만 symmetric corruption에서 이 motif와 typed head를 식별하며, finite bound는 modal recovery에 필요한 repeated-input coverage를 제시한다. Random-design greedy selector는 이 정리의 범위 밖이지만 120/120 회수는 post-review 3×3 noise grid 전체에서 안정적이었다.

별도 stress cohort에서는 unmodeled nonadditive synergy가 모든 world에서 fitted model을 nonexact하게 만들었지만 learned graph는 wrong routing 대비 0.18545의 NLL effect를 유지했다. 이 결과는 exact generator-predictor equality를 graph effect의 설명에서 제거한다. Clean-room second-language implementation은 main cohort의 모든 learned fit과 analysis mean을 재현했다. 따라서 선언한 finite stochastic population 안에서 graph information, minimal structural support, composition, misspecification과 post-export fitting/evaluation/analysis implementation reproducibility가 각각 분리되어 식별된다.

다음 결정적 비교는 factorized head와 generic sparse head의 비교가 아니다. Entity의 생성과 삭제, identity 유지 및 relation 재구성 아래에서 동일한 dependency graph를 회수한 두 model을 비교해야 한다. 이 비교가 어떤 효과를 식별하려면 두 arm이 동일한 observable information을 받아야 하며 representational commitment만 달라야 한다. Identity 또는 typed relation을 한 arm에만 input으로 제공하면 결과는 information asymmetry의 산물이 되며, 이는 원래 finite-family audit에서 진단한 것과 같은 종류의 confound다. Turnover quantity $b(p)$, 그 zero criterion과 survivor-only preservation의 vacuity 명제는 companion theory에 이미 formalize되어 있다. 따라서 turnover에 초점을 둔 연구가 이 설계의 가장 작은 self-contained instance다.

References

- [1] Kartik Ahuja, Divyat Mahajan, Yixin Wang, and Yoshua Bengio. Interventional causal representation learning. In *Proceedings of the 40th International Conference on Machine Learning*, volume 202 of *Proceedings of Machine Learning Research*, pages 372–407, 2023. URL <https://proceedings.mlr.press/v202/ahuja23a.html>.
- [2] Sohail Bahmani, Bhiksha Raj, and Petros T. Boufounos. Greedy sparsity-constrained optimization. *Journal of Machine Learning Research*, 14:807–841, 2013. URL <https://jmlr.org/papers/v14/bahmani13a.html>.
- [3] Peter Battaglia, Razvan Pascanu, Matthew Lai, Danilo Jimenez Rezende, and Koray Kavukcuoglu. Interaction networks for learning about objects, relations and physics. In *Advances in Neural Information Processing Systems*, volume 29, 2016. URL <https://proceedings.neurips.cc/paper/2016/hash/3147da8ab4a0437c15ef51a5cc7f2dc4-Abstract.html>.
- [4] Peter W. Battaglia, Jessica B. Hamrick, Victor Bapst, et al. Relational inductive biases, deep learning, and graph networks. *arXiv preprint arXiv:1806.01261*, 2018. doi: 10.48550/arXiv.1806.01261.
- [5] Simon Bing, Urmi Ninad, Jonas Wahl, and Jakob Runge. Identifying linearly-mixed causal representations from multi-node interventions. In *Proceedings of the Third Conference on Causal Learning and Reasoning*, volume 236 of *Proceedings of Machine Learning Research*, pages 843–867, 2024. URL <https://proceedings.mlr.press/v236/bing24a.html>.
- [6] Philippe Brouillard, Sébastien Lachapelle, Alexandre Lacoste, Simon Lacoste-Julien, and Alexandre Drouin. Differentiable causal discovery from interventional data. In *Advances in Neural Information Processing Systems*, volume 33, 2020. URL <https://proceedings.neurips.cc/paper/2020/hash/f8b7aa3a0d349d9562b424160ad18612-Abstract.html>.
- [7] Eva L. Dyer, Aswin C. Sankaranarayanan, and Richard G. Baraniuk. Greedy feature selection for subspace clustering. *Journal of Machine Learning Research*, 14:2487–2517, 2013. URL <https://jmlr.org/papers/v14/dyer13a.html>.
- [8] Alain Hauser and Peter Bühlmann. Characterization and greedy learning of interventional markov equivalence classes of directed acyclic graphs. *Journal of Machine Learning Research*, 13:2409–2464, 2012. URL <https://jmlr.org/papers/v13/hauser12a.html>.
- [9] Thomas Kipf, Ethan Fetaya, Kuan-Chieh Wang, Max Welling, and Richard Zemel. Neural relational inference for interacting systems. In *Proceedings of the 35th International Conference on Machine Learning*, volume 80 of *Proceedings of Machine Learning Research*, pages 2688–2697, 2018. URL <https://proceedings.mlr.press/v80/kipf18a.html>.
- [10] Thomas Kipf, Elise van der Pol, and Max Welling. Contrastive learning of structured world models. In *International Conference on Learning Representations*, 2020. URL <https://openreview.net/forum?id=H1gax6VtDB>.
- [11] Francesco Locatello, Dirk Weissenborn, Thomas Unterthiner, Aravindh Mahendran, Georg Heigold, Jakob Uszkoreit, Alexey Dosovitskiy, and Thomas Kipf. Object-centric learning with slot attention. In *Advances in Neural Information Processing Systems*, volume 33, 2020.

- URL <https://proceedings.neurips.cc/paper/2020/hash/8511df98c02ab60aea1b2356c013bc0f-Abstract.html>.
- [12] Giambattista Parascandolo, Mateo Rojas-Carulla, Niki Kilbertus, and Bernhard Schölkopf. Learning independent causal mechanisms. In *International Conference on Learning Representations*, 2018. URL <https://openreview.net/forum?id=SJky6Ry0W>.
 - [13] Cansu Sancaktar, Sebastian Blaes, and Georg Martius. Curious exploration via structured world models yields zero-shot object manipulation. In *Advances in Neural Information Processing Systems*, volume 35, 2022. doi: 10.52202/068431-1755.
 - [14] Bernhard Schölkopf, Francesco Locatello, Stefan Bauer, Nan Rosemary Ke, Nal Kalchbrenner, Anirudh Goyal, and Yoshua Bengio. Toward causal representation learning. *Proceedings of the IEEE*, 109(5):612–634, 2021. doi: 10.1109/JPROC.2021.3058954.
 - [15] Joel A. Tropp and Anna C. Gilbert. Signal recovery from random measurements via orthogonal matching pursuit. *IEEE Transactions on Information Theory*, 53(12):4655–4666, 2007. doi: 10.1109/TIT.2007.909108.
 - [16] Burak Varici, Emre Acartürk, Karthikeyan Shanmugam, and Ali Tajer. General identifiability and achievability for causal representation learning. In *Proceedings of the 27th International Conference on Artificial Intelligence and Statistics*, volume 238 of *Proceedings of Machine Learning Research*, pages 2314–2322, 2024. URL <https://proceedings.mlr.press/v238/varici24a.html>.
 - [17] Julius von Kügelgen, Michel Besserve, Liang Wendong, Luigi Gresele, Armin Kekić, Elias Bareinboim, David M. Blei, and Bernhard Schölkopf. Nonparametric identifiability of causal representations from unknown interventions. In *Advances in Neural Information Processing Systems*, volume 36, 2023. doi: 10.52202/075280-2110.
 - [18] Martin J. Wainwright. Sharp thresholds for high-dimensional and noisy sparsity recovery using ℓ_1 -constrained quadratic programming. *IEEE Transactions on Information Theory*, 55(5):2183–2202, 2009. doi: 10.1109/TIT.2009.2016018.
 - [19] Karren Yang, Abigail Katcoff, and Caroline Uhler. Characterizing and learning equivalence classes of causal DAGs under interventions. In *Proceedings of the 35th International Conference on Machine Learning*, volume 80 of *Proceedings of Machine Learning Research*, pages 5541–5550, 2018. URL <https://proceedings.mlr.press/v80/yang18a.html>.
 - [20] Xun Zheng, Bryon Aragam, Pradeep K. Ravikumar, and Eric P. Xing. DAGs with NO TEARS: Continuous optimization for structure learning. In *Advances in Neural Information Processing Systems*, volume 31, 2018. URL <https://proceedings.neurips.cc/paper/2018/hash/e347c51419ffb23ca3fd5050202f9c3d-Abstract.html>.